简历修改 Agent｜技术方案与 Agent 行为设计

版本：v0.1 · 日期：2026-10-19 · 状态：待评审的技术设计草稿

需求基线：PRD v0.2。本文提供拟采用方案、接口与验证重点，不代表已实现、已安装依赖、账户已验证或模型效果达标。本轮未调用付费 API。

1. 已确认路线与技术选择

已确认：本机运行；浏览器保存业务记录；使用 DeepSeek；文本文件先本地提取，截图 / 扫描页按需发送视觉模型；单模型先验证；本轮总预算 30 元，包含接入验证、识别、Agent 调用及重试。

1.1 方案取舍

方案	取舍	本文建议
单个 Agent，直接通过 SDK 调用模型和工具	循环、状态与权限清楚，便于逐步理解；重试和恢复需要自行实现	首版采用
单个 Agent，使用现成 Agent 框架	可复用编排能力，但增加框架概念和版本适配	出现明确需求再引入
多个专职 Agent 协作	增加交接、状态同步、费用和排障复杂度	本期不采用

技术建议：TypeScript 贯穿前后端；React + Vite 构建浏览器工作台；Node.js + Express 提供本机服务；通过兼容 SDK 访问 DeepSeek；浏览器采用 IndexedDB（Dexie 封装）。选这些工具是为了减少语言切换，便于学习与调试，不代表它们是唯一方案。具体版本在开发前验证兼容性并锁定，不现在假定已安装。

本文所有具体栈、默认参数和接口均为待评审技术建议；不改变已确认产品行为，也不自动授权开发。

1.2 运行边界

- 浏览器：界面、原附件和业务数据保存、本地解析、确认建议、编辑与导出。
- 本机后端：模型密钥、Agent 运行、工具校验、调用预算与独立成本账本。
- DeepSeek：接收必要的文本 / 图片，生成识别结果或行动选择；不直接访问浏览器数据库，也不能自行更新正式稿。
- 不引入云端业务数据库、向量数据库、联网搜索、通用代码执行、文件系统读写或 shell 工具。
- 本机服务仅绑定回环地址。建议固定工作台地址 `http://127.0.0.1:5173`，后端 `127.0.0.1:3001`，前端代理 `/api`；端口占用就报错，不自动换端口。更换主机名、端口或浏览器会形成不同的本地存储空间。

2. 模型接入与材料处理

2.1 DeepSeek 接入

候选配置：官方地址 `https://api.deepseek.com`，模型 `deepseek-flash`，Chat Completions 接口。官方文档当前列出该模型支持工具调用和图像输入；不使用旧别名，不自动切换更贵模型或第二家服务。官方接入、工具调用、图像输入

密钥只从本机后端环境变量 `DEEPSEEK_API_KEY` 读取，不使用会注入前端包的变量前缀，不写入 IndexedDB、请求日志、错误正文或下载稿。用户自行在本机配置，无需发送到聊天中。

默认关闭思考模式，先验证普通工具调用；若后续对照试验需要思考模式，再单独说明协议与成本变化。不依赖 Beta strict 功能；所有工具参数和结果均由后端进行结构校验，不将合法 JSON 等同于事实正确。思考模式说明

2.2 输入处理路线

输入	本地处理	模型收到的内容与恢复方式
粘贴 / .md	读取文本，保留行号与原始内容	有来源编号的文本；空内容提示补充
.docx	Mammoth 提取段落 / 表格相关内容并转为文本块；不执行转换生成的 HTML	文本块及来源；不能完整提取时明确提示，允许粘贴，不宣称任意 Word 版式均可靠
文字型 PDF	PDF.js 按页获取文字及位置，保留页码	按页文本块；可疑错序或内容缺失允许用户修正，必要时请求对应页的视觉读取
扫描 / 混合 PDF	PDF.js 按页检查文字层；需要识别的页渲染为图片	仅待识别页按需作为图片输入；原 PDF 顺序不变，页间部分失败可局部继续
PNG/JPEG 截图	校验实际内容、解码图片、保留原图；按需缩放，保留坐标变换	图片及识别任务；保留识别结果，后续普通改写优先复用文本

工具依据：PDF.js 页面与渲染、PDF.js 文字提取 API、Mammoth 项目说明。这些库能提供解析基础，不保证阅读顺序、文本框或复杂排版完整；尤其双栏 PDF 和 Word 浮动对象需要样例验证。

视觉识别使用同一个候选模型，是材料工具内部的一次调用，不额外建立一个自治 Agent。只转录、分类与定位，不在识别步骤润色经历。扫描页识别和截图理解都计入总预算。

截图以本次请求的内联图片发送，不发布公共图片链接；首版不使用 Files API 持久上传。已确认可复用的识别结果按附件内容摘要、页码、处理参数与识别版本缓存。重传相同材料不自动重复识别；用户主动要求重新识别时仍须通过预算检查。

2.3 自动分类与排序

解析产生材料清单后，由 Agent 依据内容识别为简历、JD、补充材料或待澄清，显示识别结果供用户纠正。未知角色不默认为个人事实；不能把 JD 要求写入用户经历。

PDF 内部页序由程序锁定。截图顺序由 Agent 结合页码、标题和内容衔接提出，并保留原附件标识；不确定则提问，不能静默删除或拼出不存在的内容。混入两份简历或两个岗位时，先确定当前会话目标，不自动合并。

建议验证起始限制：每文件 10 MiB、每会话 10 个附件、PDF 合计 20 页、粘贴与提取正文合计 50,000 字符，视觉一次处理一页 / 一图；图片最长边处理目标不超过 2,000 px，保留原图。以上用于限制测试规模，不是用户已确认的规格；用真实简历检查清晰度和容量后再定案，调整时同步 PRD。加密 PDF、损坏文件和解码失败明确报错并提供粘贴恢复。

3. 数据与依据的可追溯设计

3.1 数据对象

对象	最小字段与作用
Session	id、求职方向、当前状态、时间、stateRevision、可选 JD 引用
Attachment	id、sessionId、文件名、实际类型、内容摘要、Blob、原始序号、识别状态
SourceBlock	id、sessionId、attachmentId / messageId、材料角色、页码 / 段落 / 行号、原文、sourceRevision、识别方式
Message	id、sessionId、角色、正文、时间、是否为用户补充 / 纠正 / 跳过
DraftBlock	id、sessionId、Markdown、blockRevision、来源关联、最近写入类型
Suggestion	id、目标块及其旧版本、旧文 / 新文、操作、理由、sourceRefs、信息缺口、状态
Issue	id、范围、问题类别、优先原因、引用、未解决 / 已处理 / 已跳过状态
Run	id、sessionId、generation、输入版本、运行状态、已执行事件与错误类别

编号由程序生成，模型只能引用提供给它的编号。`sourceRefs` 指向不可变的来源快照，不只保存一段会变化的摘要。来源校验必须确认引用属于当前会话且确实存在；文字引用必须能对应快照，但这只能验证“来自哪里”，不能证明经历真实或改写在语义上完全忠实。

材料被纠正时创建新来源版本，保留旧版本供解释历史建议。用户直接编辑正式稿标记为 `user_edit`，不把新增文字自动归因于旧材料。无来源的模型推断不能标为已证实个人事实。

3.2 初始稿与建议

初始稿依据已识别为简历的来源块组装，保留信息和顺序，仅做必要的 Markdown 格式整理；不在此阶段擅自优化、删减或加入 JD。无法确定格式转换是否改变含义时，作为建议呈现，不写入初始稿。

建议操作限定为替换、插入或删除一个独立块，必要时以独立字段建块；携带 `blockId`、`expectedBlockRevision` 和旧内容。模型提交建议后，后端校验目标和来源，但不改正式稿。用户接受时，浏览器再次核对目标块版本，在一次本地事务中更新正文、建议状态与来源关联。

整稿编辑采用完整 Markdown 编辑器。保存时按顶层标题 / 段落 / 列表项分块并对照旧稿：确定未变的块保留编号；改变、合并、拆分或无法唯一对应的块分配新版本 / 编号，并使相应旧建议失效。无法安全映射时宁可扩大失效范围，不按相似文字猜测并覆盖。实现需测试重复段落和列表嵌套。

插入位置要引用相邻块及版本。无论重复接受还是连续点击，都不得重复插入。用户拒绝只改建议状态；要求调整创建新建议并关联旧建议，不篡改历史依据。

3.3 保存与删除

业务对象和原附件 Blob 保存在同一浏览器的 IndexedDB；Dexie 提供事务封装。事务中只做数据库读写，不等待模型或网络；完整提交后才显示“已保存”。Dexie 事务说明

自动保存对话、建议处理和稿件变化；直接编辑建议在停顿约 500 ms 后保存，并在切换会话前等待提交。保存失败保留可见内容、提示尚未持久化，允许导出；不能指望关闭页面事件保证保存。重开时将遗留运行标记为已中断，不自动重发付费请求。

删除整会话时，先使运行代号失效并尽力取消请求，再在事务中删除会话、附件、文本、问答、建议、依据和当前稿。所有迟到响应写入前必须检查会话存在及运行代号，不能重新建立已删除会话。已发出的模型调用可能仍产生费用，本机成本账本不随会话删除。

首版同一浏览器配置只允许一个工作台标签编辑：通过同源标签协调检测第二个标签，第二个只显示已打开提示，避免两份内存状态互相覆盖。此为技术建议，需浏览器验证，不扩展跨设备同步。

4. Agent 的循环、工具与停止条件

4.1 每轮如何运行

用户点击开始、回答问题或提出新要求后，程序创建本次运行，把目标、当前稿、材料清单、未解决问题、有效建议和最近反馈提供给模型。模型按当前情况决定行动；材料多时通过工具取原文，不把其他会话或全部历史无条件塞入。

一次模型响应可以请求工具，也可以结束本轮等待用户。后端校验工具名、参数、会话范围与预算，执行后将结果与原 `tool_call_id` 成对返回模型，再由模型判断下一步。首次必须给出最多 3 个重要诊断点，但不规定后续必须“先追问再改写”。

示例：发现“项目推进”缺细节 → 查找本会话补充 → 已有具体行动则提交建议；若无则追问；用户说记不清时有限改写或转向其他问题。新回答纠正已接受职责时，主动查找相关表述并标记冲突，再提出待确认纠正。

4.2 提供给模型的工具

工具	输入 → 输出	权限边界
read_material	来源编号、页码范围 → 来源块与定位	仅当前会话；不接受任意路径或 URL
recognize_page	当前附件 / 页编号、原因 → 识别文本与来源块	只处理已上传材料；命中缓存先复用，新调用经统一预算控制
set_material_interpretation	材料角色、截图顺序、依据 / 歧义 → 分类结果或澄清项	不能改变 PDF 页序；用户纠正优先
search_evidence	关键词、可选来源范围 → 匹配原文及编号	普通文本检索即可，不新增向量库 / RAG；不得跨会话
read_draft	块编号范围 → 当前块与版本	只读最新可用稿，不将待接受建议当正式内容
record_issues	问题、优先理由、来源、受影响块 → 诊断 / 冲突记录	标记问题，不直接改写正文
	操作、目标版本、新文、理	

工具	输入来源	输出	权限边界
propose_change	操作、目标版本、理由、建议	缺口 → 待确认建议	没有正式稿写入权限；不能接受自己的建议

问用户、说明进展和给交付总结由结构化回合结果呈现，不为每句话造工具。模型只能使用白名单工具，不能自行触发接受、删除会话、导出文件、提高预算、修改密钥或联网搜索。

4.3 程序约束与可见状态

- 建议默认：每次用户触发运行最多 6 次付费模型请求（含视觉），最多 12 次工具执行，每次模型输出上限 4,096 tokens。SDK 自动重试关闭；这些是保护循环的上限，不是固定追问轮数。
- 遇到需要回答、需要用户接受建议、达到上限、预算不足、错误或用户打断时结束本轮；已经完成的诊断和建议仍保留。
- 校验失败时最多允许一次受预算控制的模型修复，仍计入本轮请求上限；不能因为格式错误无限循环。用户拒绝不是错误，不自动反复生成相同建议。
- 状态为 idle、running、waiting_user、interrupted、failed、budget_blocked；状态管理由程序执行，不让模型宣称某项写入已完成。
- 相同内容反复调用工具且无新增结果时停止并解释卡点。达上限不代表任务完成，用户可明确选择继续。
- 已发送的调用取消后不保证不计费；不能在 Abort 后自动退回预算预留。

5. 前后端接口与失效控制

以下是建议契约，不是现有接口。前端读取本地状态，后端只保留本次运行必需的内存快照，不建立服务器简历数据库。

接口	请求与返回	责任
GET /api/health	配置是否就绪、候选模型、价格快照时间	只报告状态，不返回密钥，不自动调用付费模型
GET /api/budget	已记录费用、未知费用预留、可用预算及是否阻断	返回本项目账本，不冒充服务商最终账单
POST /api/agent/runs	requestId、sessionId、generation、stateRevision、必要会话快照及触发事件 → 运行事件流	校验与去重，启动有限循环；附件只发送实际需要的图页
POST /api/agent/runs/:id/tool-result	运行代号、toolCallId、本地资料读取结果 → 确认	仅回应服务端已发出的读取请求；不接受任意工具或越权写入
POST /api/agent/runs/:id/cancel	当前运行代号 → 尽力取消结果	取消后客户端不再应用该代号的结果

运行事件通过 fetch 流返回，事件包含 sessionId、runId、generation、序号、类型和必要数据。类型限定为进度、工具请求、诊断、问题、建议、冲突、结束、错误。前端只持久化经过校验的完整事件，不把尚未收全的 JSON 或流式文字当可接受建议。

后端 read_material / search_evidence 等首先使用当前输入快照；确需未包含的本地材料时发出带限定来源的工具请求，由浏览器读取并回复。视觉工具的图片也经这一路径按需提供。等待本地结果超时则结束运行并保留状态，不生成虚构工具结果。

统一错误类别：invalid_input、parse_failed、ambiguous_material、stale_state、invalid_tool、invalid_model_output、provider_error、budget_exceeded、storage_failed、cancelled。错误返回可执行的恢复动作，不暴露密钥或原文堆栈。

同一会话只允许一个运行；用户编辑、纠正、接受建议时取消旧运行并增加 stateRevision。工具执行及事件应用检查 sessionId、generation 和预期版本：不一致就丢弃旧事件。切换会话默认取消当前运行，成功持久化的内容仍保留；服务端保留有时限的请求去重记录，防断线重连导致重复付费。

仅接受本机工作台 Origin；拒绝跨站请求，使用启动时生成的本地请求令牌保护产生费用的接口。该令牌不是账号功能，不写入用户历史。模型请求目标固定为配置的服务地址，材料中的 URL 不能转为服务器请求。

6. 30 元预算与费用账本

6.1 费率依据与保守预留

2026-10-19 官方中文价格页列出 Flash 高峰未命中输入 2 元 / 百万 tokens、输出 8 元 / 百万 tokens。以较高费率估算，不把缓存或空闲折扣当成必定发生。官方价格页

建议每次付费请求先预留 3 元。此数不是预计单次费用，而是按当前公布的约 1M 上下文规模、上述较高输入价格及 4,096 输出上限留出的保守保护额。实施前必须重新核实上下文、图片计量、实际账号币种及费率；无法成立则不启用付费调用。不能在别名、计费或输出上限改变后继续沿用旧预留。

成功后根据返回 usage，按较高未缓存输入与输出费率记账，释放多余预留；缓存和折扣不必用于扩大预算。无 usage、超时、连接中断、取消等无法确认费用的调用保留整笔预留，不推定为零；先核账再释放。预留不足以容纳下一次调用时提前停止，即使最终真实费用可能很低。

6.2 账本独立保存

- 本机后端在项目忽略目录 `.local/` 保存不含简历内容和密钥的成本账本：请求编号、模型、费率快照、预留、usage、已记费用、未知状态与时间；不在本轮创建该目录或实际账本。
- 金额采用人民币微元整数运算，所有费用上取整；总额 30,000,000 微元。将“已计费用 + 未结预留 + 下一请求预留”与总额比较。
- 单进程串行进行费用预留并原子落盘；账本写入失败不得调用模型。仅允许一个后端实例；请求重试也必须重新预留，不能共享已用的预留。
- 后端重启后未结预留继续占用；新建、删除会话或清空浏览器不清零账本。历史接入测试若已消费，需要在本轮起始余额核对中计入。
- 首次试用记录服务商余额基线，试用后核对；余额接口是账户总额，其他应用消费、充值或赠金到期都可能干扰差值，不能当作本项目精确流水。余额接口
- 未配置模型、费率或有效账本时停止付费入口。本应用只能约束经本机服务发起的调用，不能限制该账号在其他工具中的支出，也不能把估算账本宣称为服务商账单。

预算阻断时原附件回看、手动编辑、复制与 Markdown 下载仍可用。增加预算必须由发起者另行明确决定，Agent 无此工具权限。

7. 验证顺序、风险与评审

7.1 先验证什么

1. 不付费先验证本地文件解析和来源定位：MD、DOCX、文字 PDF、双栏 PDF、图片与扫描页渲染；检查漏字、错序、表格与浮动对象。
2. 以模拟模型响应验证工具白名单、来源校验、逐条接受、重复操作、直接编辑失效、取消后迟到响应、删除与本地恢复、预算预留；先证明权限由程序控制。
3. 配置由用户保管的密钥后，在总预算内验证一条普通工具调用和一张构造 / 脱敏图片，不先做大批量调用；记录模型、参数、实际 usage、费用与输出。
4. 用同一段经历的三种情境检验自主性：已有足够依据、缺少关键行动、用户不愿补充；观察是否分别选择直接建议、关键追问和有限改写 / 转向。
5. 对照 PRD 的 23 项用例记录实际结果；技术测试新增请求去重、版本冲突、账本重启和本地标签协同。独立测试与评估方案另行细化。

7.2 未验证风险

风险	处理与不作的承诺
模型图片缩放可能影响小字和数字识别	用实际截图测试，可按页 / 区域重读；不能以低分辨率省钱后声称内容完整
DOCX 浮动对象、PDF 阅读顺序不可靠	保留原件和定位，异常提示修正 / 粘贴；不能静默删掉无法提取的经历
来源引用正确但改写仍夸大	程序只验证可定位与权限，语义需规则、样例评估和用户确认共同约束
浏览器保存被清理或超限	明示本地保存边界、提供导出、失败不报成功；不承诺永久保存
预算估计与真实计费差异	先预留、关闭自动重试、未知费用不释放、核实费率和余额；不冒充账户级硬限额
不同岗位诊断水平不一	标明限制，按试过的岗位记录效果，不将目标范围当成验证范围

7.3 评审结论与下一步

已确认的是模型服务与处理路线；本文提出的语言栈、轻量 Agent 循环、浏览器 / 后端职责、接口、默认限制与预算预留尚待用户评审。用户主要评审模块分工、理解成本、Agent 是否自主，以及是否接受这些工程约束；不要求用户代替开发核实库版本。

通过本技术方案后，下一份产出是《测试与评估方案》，再形成《开发与交付计划》。若样例验证表明需求无法可靠实现，应列出受影响的 PRD 条目与取舍，不自行改成不支持截图或取消追溯。

当前未安装依赖、未开发产品、未执行模型调用或验证；所有“成功”均是预期行为而非实测结论。